

基于视觉语言模型的食物图像理解与营养分析：文献综述

Abstract

食物图像的自动化识别与营养分析是计算机视觉与健康管理交叉领域的重要课题。传统方法依赖卷积神经网络进行封闭集分类与级联式流程处理，难以应对真实场景中食物类别的开放性和多样性。随着视觉语言模型（Vision-Language Model, VLM）的兴起，食物理解任务正从单一的分类向开放词汇识别、多模态对话、智能体交互等方向演进。本文系统梳理了该领域的五大核心方向：食物图像识别与分类、食物分量与体积估计、营养成分与能量（卡路里）估计、VLM 在食物理解中的前沿应用，以及智能体架构在健康管理中的探索。通过对各方向关键技术与代表性工作的分析，本文揭示了当前研究的主要进展与局限，并展望了未来基于 VLM 的食物能量（卡路里）识别智能体的发展方向。

1 引言

饮食健康管理是当代社会的重要议题。不合理的饮食习惯是导致心血管疾病、糖尿病等慢性病的主要风险因素。在这一背景下，如何便捷、准确地记录和分析日常饮食摄入成为一项迫切需求。传统的饮食评估方法如 24 小时膳食回顾法和饮食记录，依赖用户的记忆和自我报告，操作繁琐且误差较大。文献调研表明，传统自我报告方法的估算误差可达显著水平。

图像辅助饮食评估（Image-Assisted Dietary Assessment, IADA）的兴起为这一问题提供了新的解决路径。用户只需拍摄食物照片，系统即可自动完成食物识别、分量估计和营养分析。自 2015 年以来，深度学习算法已逐步取代传统的手工特征机器学习方法，成为 IADA 系统的主流技术路线。

视觉语言模型的出现标志着该领域的又一次范式转变。CVPR 2025 Workshops 上的一项系统性评估指出，VLM 通过整合视觉与文本推理能力，为食物识别与营养评估提供了新的可能性。与传统 CNN 方法相比，VLM 具备开放词汇识别能力、跨模态对齐能力和零样本泛化能力，为食物理解任务提供了新的技术基础。与此同时，基于大语言模型的智能体（Agent）架构正将饮食评估从单次推理推向多轮交互的对话式范式。

2 食物图像识别与分类

2.1 传统 CNN 方法与经典数据集

食物图像分类是细粒度视觉分类的典型任务，其核心挑战在于：不同类别之间差异细微，而同一类别内部差异巨大。这种“类间小、类内大”的特性使得食物识别远复杂于通用物体识别。

在数据集方面，**Food-101** 是该领域最具影响力的基准之一。Bossard 等人于 2014 年 ECCV 上提出了这一数据集，涵盖 101 个食物类别、总计 101,000 张图像。该数据集的设计特意保留了训练图像中的噪声以模拟真实世界的图像分布，至今已被引用超过 2600 次。在 Food-101 基准上，主流 CNN 模型如 Inception V3 可达约 88.28% 的 Top-1 准确率，ResNet-200 约为 79.12%。此外，大规模食物数据集不断涌现，如 **Food2K**（2000 类别、超 100 万图像）和 **ISIA Food-500**（500 类别、近 40 万图像），为深度模型的训练提供了更丰富的数据支撑。

在主干网络层面，卷积神经网络长期是该领域的主导架构。研究者通常将 ResNet、VGG、Inception 等标准 CNN 架构与注意力或部位定位模块相结合，以克服 CNN 在建模长程空间关系方面的局限性。Vision Transformer 的引入代表了该领域的范式转变——与 CNN 依赖局部感受野不同，ViT 通过自注意力机制直接建模全局依赖关系。

Nutrition5k 数据集的提出进一步推动了该方向的发展。Thames 等人于 CVPR 2021 上提出了这一数据集，包含 5,066 种真实世界食物菜品，配有视频流、深度图像、成分重量和高精度营养标注。研究者基于此训练了能够从单张 RGB 图像预测能量（卡路里）和宏量营养素含量的深度 CNN 模型，其精度甚至超过了专业营养师的视觉估计能力。

2.2 从封闭集到开放词汇识别

传统食物识别受限于封闭集假设——模型只能在预定义类别集合内进行分类。视觉语言模型为这一困境提供了解决方案。**CLIP**（Contrastive Language-Image Pre-Training）通过大规模图文对比学习，建立视

觉与语言空间的跨模态对齐，使零样本食物识别成为可能。其核心机制是利用 4 亿对图文数据进行对比预训练，将图像和文本编码到统一的嵌入空间，从而支持任意文本描述的零样本分类。

在食物领域的零样本分类评测中，**Food-500 Cap** 基准的建立揭示了一个重要现象。Ma 等人在 ACMMM 2023 上构建了包含 24,700 张图像、494 个类别的食物图像描述数据集，通过细粒度的食物属性标注和烹饪文化分类学，系统评估了九种主流 VLM 的性能。实验发现，VLM 在食物分类中表现出显著的烹饪文化偏见——模型在识别西方和拉丁美洲食物时表现较好，而在亚洲食物上性能显著下降。这种偏见继承自预训练数据集中食物地理分布的不均衡：欧洲和美国食物的出现频率远高于日本等亚洲国家。FoodieQA 数据集的评测进一步印证了这一点：在涉及中国区域饮食文化的多图像视觉问答任务中，开源 VLM 的准确率仅为约 50.87%，而人类准确率高达 91.69%。这一发现对构建多语言、多文化的食物理解系统具有重要警示意义。

3 食物分量与体积估计

3.1 分量估计的挑战与技术路线

从单张 2D 图像估计食物分量是该领域最具挑战性的问题之一。图像缺乏深度信息，同一体积的食物因密度差异能量（卡路里）可能相差数倍；食物形状不规则；拍摄角度和距离不确定。近期研究进一步揭示，分量估计误差还与食物类别和分量大小高度相关：AI 模型在小份量和视觉复杂度高的食物上误差显著增大。

分量估计的技术路线主要包括：

- 参考物标定法：利用餐盘、硬币、信用卡等已知尺寸的参照物推算食物体积。代表性工作如 Fang 等人（ACMMM 2022）提出的基于参考物的食物分量估计方法，通过检测场景中的已知尺寸物体来校准尺度。
- 深度估计法：利用单目深度估计模型从 2D 图像推断 3D 结构。Chen 等人（CVPR 2024）探索了基于深度学习的食物体积预测方法。
- 多视角/三维重建法：需要用户从多个角度拍摄，精度较高但对用户不友好。
- 传感器融合法：结合 RGB 图像与深度传感器数据。Nutrition5k 数据集利用 Intel RealSense 相机捕获 RGB-D 图像，为分量估计提供了额外的 3D 信息。
- 端到端多任务模型：最新的研究趋势是将检测与分量估计集成于单一模型。Sanatbyek 等人（IEEE Access, 2025）基于 YOLOv12 架构提出的多任务模型，在自建的 Food Portion Benchmark (FPB) 数据集上实现了 0.978 的检测 mAP50 和 90.95 克的重量估计 MAE。

3.2 系统性能现状

现有系统的分量估计精度仍存在较大差距。一项针对中亚地区食物分量估计的对比研究（*The Journal of Nutrition*, 2026）提供了系统的性能画像。该研究比较了三种估计方式：视觉食物图谱辅助估计（Atlas-assisted）、AI 模型估计和无辅助人类视觉估计。结果表明，图谱辅助估计精度最高（MAE = 80.81 g, MAPE = 44.76%），无辅助估计精度最低（MAE = 133.86 g, MAPE = 79.40%），AI 模型居中（MAE = 97.37 g, MAPE = 67.81%），三种方法间的差异具有统计学意义（ $p < 0.05$ ）。值得注意的是，AI 模型在饮料类食物上表现最佳（MAE = 34.48 g, MAPE = 11.79%），但在小份量和视觉复杂度高的食物上误差显著增大，且其估计精度在不同食物类别和分量大小上波动较大。性别差异方面，仅在无辅助估计组中观察到显著性差异（ $p = 0.038$ ），男性倾向于估计更大的分量，而图谱辅助几乎消除了性别相关的估计偏差（ $p = 0.114$ ）。

图谱辅助估计（MAE=80.81g）仍显著优于 AI 模型（MAE=97.37g），这一差距揭示了一个关键事实：当前 VLM 在“利用已知参考物进行尺度推理”方面的能力远未发挥到极致。若为 VLM 提供明确的尺度参照（如硬币检测结果），其估计精度可能显著收敛。因此，分量估计的瓶颈不仅在于 2D→3D 的物理信息缺失，更在于模型对场景中已有尺度线索的利用能力不足。这一认识将研究方向从“如何获取更多深度信息”转向“如何更好地利用可见尺度参照”。

此外，在提供总菜品质量的情况下，VLM 的能量（卡路里）估计误差可从约 51% 降至约 29%。然而，即使提供了几乎所有可用的上下文线索，模型在估计酱汁和油脂等隐形成分时仍存在持续误差。

新近提出的 **DiningBench** 基准（Jin 等，arXiv 2026）进一步揭示了当前 VLM 在营养估计任务上的系统性短板。该基准包含 3,021 道菜品，平均每道 5.27 张多视角图像，对 29 种主流开源和闭源模型的评测表明，现有 VLM 在细粒度视觉判别和精确营养推理方面仍面临显著困难。

4 营养成分与能量（卡路里）估计

4.1 传统“识别-查表-计算”流程

传统 IADA 系统采用级联式流程架构：分割 → 食物识别 → 分量估计 → 营养成分计算。营养成分的计算依赖食物成分表，将识别出的食物与数据库条目匹配后，乘以估计的分量得到营养数值。这种流程的优点是透明、可解释，但误差会沿流程逐级累积。以具体数值为例：若识别模块将“红烧肉”误判为“回锅肉”（误差 5%），分量估计偏差约 20%，最终能量（卡路里）估算误差可能放大至 26% 以上。

多模态深度学习系统的最新进展结合了零样本 CLIP 识别与多视角立体视觉体积估计，在 **CNFOOD-241** 数据集上进行了验证。CNFOOD-241 是一个中国食物数据集，通过扩展 ChineseFoodNet 构建，包含 241 个类别，保留了图像原始宽高比并统一标准化为 600×600 像素，相对不平衡的数据分布使其成为更具挑战性的实验基准。

4.2 VLM 端到端方法与结构化推理

近年来的研究探索了基于 VLM 的端到端能量（卡路里）估计方法。Wang 等人对主流 VLM 在 Nutrition5K 数据集上的成分识别和营养估计能力进行了系统比较，发现虽然多数 VLM 能有效识别主要食材成分，但在营养成分的量化估计上仍面临挑战，特别是对复合菜肴或视觉上模糊的菜品。

结构化推理策略的引入已显示出显著改善效果。Khlaisamniang 等人在 CVPR 2025 Workshops 上提出了一种受营养专家工作流程启发的两步提示框架：第一步将菜品分解为食材列表、分量大小和烹饪细节，第二步计算总热量和宏量营养素。实验在 Nutrition5K 子集（Nutrition320）和 Gindee 应用真实数据（Gindee121）上验证，结果表明“先分解后计算”的两步推理显著优于单步直接查询，且视觉提示（如边界框和分割掩码）进一步增强了方法的鲁棒性。

值得注意的是，菜品级营养标注（如 Nutrition5K 提供整道菜的总热量）与成分级推理（VLM 尝试拆解食材逐一计算）之间存在任务定义的张力。下表对比了两种范式的核心差异：

范式	误差来源	可解释性	标注成本
菜品级直接回归	模型全局拟合误差	低	低（实验室化学分析）
食材级分解汇总	识别 + 分量 + 成分三级误差叠加	高	高（需精细成分标注）

菜品级标注提供真实值但缺乏成分细节，成分级推理提供可解释性但引入额外推理误差。这一“任务定义层面的根本矛盾”是未来数据构建和模型设计需共同面对的核心问题。

此外，级联式流程与 VLM 端到端方法之间也存在深层张力。级联式流程的优势在于透明、可解释、可逐环节调试，符合 FDA 等监管机构对医疗 AI 的可解释性要求；而 VLM 端到端方法虽在跨模态对齐上表现优异，其“黑盒”特性在临床部署中面临监管障碍。未来更可能的方向是“可解释的端到端”——即 VLM 输出结构化推理链（如两步提示法），同时保留对中间结果（食材列表、分量估计）的审计能力。这一方向已在 Khlaisamniang 等人的工作中初见端倪。

5 视觉语言模型在食物理解中的前沿应用

5.1 VLM 能力与局限

VLM 在食物理解中的核心优势包括开放词汇识别能力、视觉问答能力和跨模态推理能力。CVPR 2025 Workshops 上的一项系统性评估对六个 SOTA VLM 在食物识别任务上进行了全面评测，结果表明闭源模型显著优于开源模型，但所有模型在细粒度食物识别上仍面临挑战。

然而，VLM 在食物场景中面临独特挑战：

- **幻觉问题（Hallucination）**：模型可能编造不存在的食材或营养信息。在食物场景中，这种幻觉可能表现为凭空添加未出现在图像中的食材。有趣的是，结构化推理策略（如两步提示法）对缓解幻觉有一定作用——通过强制模型先“分解”再“计算”，减少了编造成分的空间。
- **数值推理能力弱**：能量（卡路里）计算需要精确算术，而 VLM 在数值推理方面存在天然短板。
- **物理尺度感知缺乏**：模型难以从图像中准确判断食物的大小和分量。
- **多图像理解困难**：FoodieQA 基准评测表明，开源 VLM 在多图像视觉问答任务上准确率仅约 50.87%，远低于人类水平。

5.2 中餐场景的独特性与数据偏见问题

中餐食物理解面临特殊挑战。Food-500 Cap 基准的评测表明，VLM 在区域性菜系识别上存在显著的文化偏见。训练数据的地理和文化偏见是该领域面临的系统性问题：现有大规模数据集主要来源于西方国家，导致模型在识别非西方菜系时性能急剧下降。

FoodieQA 数据集的构建专门针对中国饮食文化的区域多样性，涵盖 14 种中国菜系类型。其评测结果进一步揭示了 VLM 在中国食物文化理解上的系统性不足：API 闭源模型的表现接近人类（差距在 10% 以内），但开源模型在多图像任务上落后人类达 41%。

具体而言，中餐场景的独特性体现在：

- 共享菜与分餐制的差异：西餐多为单人份，中餐常为多人共享，需从共享菜品中估计个人摄入量。
- 烹饪方式的多样性：炒、蒸、炸、炖等多种烹饪方法导致同一食材外观差异巨大。
- 食材形态变化：如整条鱼与鱼片在视觉特征上截然不同，增加了识别难度。

针对这一问题，已有研究者探索了 **Chinese CLIP**（Yang 等，2022）等中文双语模型，尝试减轻语言和文化偏见。

6 智能体架构在饮食健康中的应用

6.1 从单次推理到多轮交互

传统饮食评估是一次性推理。智能体（**Agent**）架构将这一过程转化为多轮对话范式，使用户能够追问细节并接收个性化建议。

多模态 **Agent** 在饮食评估中的代表性探索来自 CVPR 2026 研讨会的工作，研究者提出了一种 **Agentic** 视觉语言管道，通过逐步整合上下文线索来改善营养预测。实验比较了两种推理策略：结构化思维链提示和 **Agentic** 自提问（模型动态生成澄清性问题，如“这份沙拉里放橄榄油了吗？”“这个汉堡的肉饼大概多厚？”），结果表明交互式提问通过解决食材和分量的不确定性，显著降低了能量（卡路里）估计误差。

然而，多轮交互的有效性需与用户负担相平衡。若每道菜需回答 3-5 个澄清性问题，用户可能因操作繁琐而放弃使用。因此，**Agent** 设计需在“主动提问”与“被动感知”之间寻找平衡：一方面，仅在不确定性阈值以上触发提问；另一方面，融合可穿戴设备（如智能餐盘重量变化、用餐时长检测）等隐式上下文信号，减少对用户主动输入的依赖。

6.2 个性化 Agent 的设计实践

Purrfessor 系统是一个基于 LLaVA 微调的食物健康聊天机器人的典型案例。该系统通过整合 USDA FoodData Central 数据库构建指令微调数据集，使 LLaVA 获得食物识别与营养分析能力。研究通过 2×3 的实验设计（Bot vs. Pet 形象 × GPT-4 vs. LLaVA vs. 微调 LLaVA）发现，宠物形象的微调 LLaVA 显著增强了用户对关怀感和兴趣度的感知。这一发现揭示了对话式健康 **Agent** 中交互设计与情感连接的重要性。

Agent 在健康管理应用中的安全性与护栏机制同样值得关注。**AgentClinic** 基准（Schmidgall 等，npj Digital Medicine, 2026）在临床模拟环境中的研究表明，**Agent** 的偏见可导致诊断准确率下降，并影响患者依从性和信任度。类似地，饮食健康 **Agent** 提供营养建议时需建立专家介入机制和事实核查护栏。**Google Research** 提出的 Personal Health **Agent** 框架（Metwally 等，2025）通过多智能体协作（数据科学 **Agent**、健康领域专家 **Agent**、健康教练 **Agent**）来平衡个性化与可靠性，为这一方向提供了系统化设计参考。

7 总结与展望

本文系统梳理了基于 VLM 的食物图像理解与营养分析的研究进展。食物识别已从 CNN 封闭集分类演进至 VLM 开放词汇识别，但文化偏见和区域性菜系的识别仍是重大挑战。分量估计是该领域最大技术瓶颈，现有方法相对误差普遍在 40%-80% 之间，但在传感器融合和端到端多任务模型方面正取得进展。营养计算正从级联式流程向结构化推理方案演进，但菜品级标注与成分级推理之间的范式张力仍需关注。VLM 应用展现出开放词汇、多模态推理等优势，但幻觉问题和数值推理短板限制了其直接用于临床场景。**Agent** 架构正将饮食评估从单次推理推向多轮交互范式，但用户负担与交互效率的平衡是工程落地的关键。

未来研究方向包括：

1. 构建覆盖全球菜系的文化多样化数据集：如 FoodieQA、DiningBench 等新基准已在拓展文化覆盖面方面做出探索。

2. 进一步探索结构化推理与 **RAG** 增强的 **VLM** 结合：将两步分解策略与外部知识检索（如 USDA FoodData Central、中国食物成分表）结合，在保持可解释性的同时提升营养估计准确性。这可能是短期内最可行的临床落地路径。
3. 发展 **Agentic** 架构以支持更自然的用户交互和个性化饮食管理，同时注重主动感知与被动感知的平衡。
4. 引入注册营养师参与系统设计与评估，确保医学可靠性。
5. 多模态数据融合：将食物图像与语音输入（用户口述食材）、可穿戴设备数据（活动量）、电子健康记录结合，构建更全面的个人健康画像。
6. 生成式反事实推理与个性化营养干预：给定一张食物图像，VLM 能否回答“如果减少一半油，这道菜看起来会怎样？营养会变化多少？”这类“what-if”问题，涉及模型对烹饪物理过程的内部建模能力。这一能力对于个性化营养干预具有独特价值——用户不仅知道“吃了什么”，还能直观理解“如何吃得更健康”。这一方向呼唤 VLM 在因果推理和物理常识建模方面的进一步突破。
7. 临床落地的监管路径探索：推动“可解释的端到端”架构，使 VLM 输出结构化推理链的同时保留对中间结果的审计能力，以满足医疗 AI 监管要求。

References

- [1] Ma, Z., Pan, M., Wu, W., Cheng, K., Zhang, J., Huang, S., & Chen, J. Food-500 Cap: A Fine-Grained Food Caption Benchmark for Evaluating Vision-Language Models. *Proceedings of the 31st ACM International Conference on Multimedia (ACMMM)*, 2023. <https://arxiv.org/abs/2308.03151>
- [2] Thames, Q., Karpur, A., Norris, W., Xia, F., Panait, L., Weyand, T., & Sim, J. Nutrition5k: Towards Automatic Nutritional Understanding of Generic Food. *arXiv:2103.03375*, 2021. <https://arxiv.org/abs/2103.03375>
- [3] Lu, L., Deng, Y., Tian, C., Yang, S., & Shah, D. Purrfessor: A Fine-tuned Multimodal LLaVA Diet Health Chatbot. *arXiv:2411.14925*, 2024. <https://arxiv.org/abs/2411.14925>
- [4] Chen, C.-S., Chen, G.-Y., Zhou, D., Jiang, D., & Chen, D.-S. Res-VMamba: Fine-Grained Food Category Visual Classification Using Selective State Space Models with Deep Residual Learning. *arXiv:2402.15761*, 2024. <https://arxiv.org/abs/2402.15761>
- [5] Romero-Tapiador, S., Tolosana, R., Lacruz-Pleguezuelos, B., Marcos-Zambrano, L. J., Bazán, G. X., Espinosa-Salinas, I., Fierrez, J., Ortega-Garcia, J., de Santa Pau, E. C., & Morales, A. Are Vision-Language Models Ready for Dietary Assessment? Exploring the Next Frontier in AI-Powered Food Image Recognition. *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition Workshops (CVPRW)*, 2025.
- [6] Bhatambarekar, G. & Sarkar, A. An Agentic Vision-Language Pipeline for Interactive Nutritional Estimation from Food Images. *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition Workshops (CVPRW)*, 2026.
- [7] Thames, Q., Karpur, A., Norris, W., Xia, F., Panait, L., Weyand, T., & Sim, J. Nutrition5k Dataset. GitHub Repository, 2021. <https://github.com/google-research-datasets/Nutrition5k>
- [8] Google Research. Nutrition5k Dataset Official Download. Google Cloud Storage, 2021. https://storage.cloud.google.com/nutrition5k_dataset/nutrition5k_dataset.tar.gz
- [9] Bossard, L., Guillaumin, M., & Van Gool, L. Food-101 – Mining Discriminative Components with Random Forests. *Proceedings of the 13th European Conference on Computer Vision (ECCV)*, 2014, LNCS 8694, pp. 446-461.
- [10] Radford, A., Kim, J. W., Hallacy, C., Ramesh, A., Goh, G., Agarwal, S., Sastry, G., Askell, A., Mishkin, P., Clark, J., Krueger, G., & Sutskever, I. Learning Transferable Visual Models From Natural Language Supervision. *Proceedings of the 38th International Conference on Machine Learning (ICML)*, 2021, pp. 8748-8763. <https://proceedings.mlr.press/v139/radford21a.html>

- [11] Liu, H., Li, C., Wu, Q., & Lee, Y. J. Visual Instruction Tuning (LLaVA). *Advances in Neural Information Processing Systems (NeurIPS)*, 2023.
- [12] Yang, A., et al. Chinese CLIP: Contrastive Vision-Language Pretraining in Chinese. *arXiv:2211.01335*, 2022. <https://arxiv.org/abs/2211.01335>
- [13] Min, W., et al. Food2K: A Large-Scale Food Image Dataset. *Proceedings of the 28th ACM International Conference on Multimedia (ACMMM)*, 2020.
- [14] Jiang, L., et al. CNFOOD-241: A Multi-Modal Food Dataset for Fine-Grained Food Recognition. *Scientific Data*, 2024.
- [15] He, K., Zhang, X., Ren, S., & Sun, J. Deep Residual Learning for Image Recognition. *Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition (CVPR)*, 2016. https://openaccess.thecvf.com/content_cvpr_2016/html/He_Deep_Residual_Learning_CVPR_2016_paper.html
- [16] Dosovitskiy, A., et al. An Image is Worth 16x16 Words: Transformers for Image Recognition at Scale. *International Conference on Learning Representations (ICLR)*, 2021. <https://openreview.net/forum?id=YicbFdNTTy>
- [17] Khlaisamniang, P., Kerdthaisong, K., Vorathammathorn, S., Yongsatianchot, N., Phimsiri, H., Chinkamol, A., Thitsesaeng, T., Veerakanjana, K., Kachai, K., Ittichaiwong, P., & Saengja, T. Decomposing Food Images for Better Nutrition Analysis: A Nutritionist-Inspired Two-Step Multimodal LLM Approach. *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition Workshops (CVPRW)*, 2025, pp. 482-491. https://openaccess.thecvf.com/content/CVPR2025W/MTF/html/Khlaisamniang-Decomposing_Food_Images_for_Better_Nutrition_Analysis_A_Nutritionist-Inspired_Two-Step_CVPRW_2025_paper.html
- [18] Smart Food Area-Weight System for Dietary and Nutritional Monitoring. *IEEE Sensors Journal*, Vol. 25, Issue 24, 15 December 2025, pp. 44522-44534. <https://ieeexplore.ieee.org/abstract/document/11205992>
- [19] Jin, S., Zhang, J., Zhang, X., Tian, Z., Jiang, F., Yin, G., Lin, W., Liu, Y., & Yan, R. DiningBench: A Hierarchical Multi-view Benchmark for Perception and Reasoning in the Dietary Domain. *arXiv:2604.10425*, 2026. <https://arxiv.org/abs/2604.10425>
- [20] Li, W., Zhang, X., Li, J., Peng, Q., Tang, R., Zhou, L., Zhang, W., Hu, G., Yuan, Y., Søgaard, A., Herscovich, D., & Elliott, D. FoodieQA: A Multimodal Dataset for Fine-Grained Understanding of Chinese Food Culture. *arXiv:2406.11030*, 2024. <https://arxiv.org/abs/2406.11030>
- [21] Sanatbyek, A., Rakhimzhanova, T., Nurmanova, B., Omarova, Z., Rakhmankulova, A., Orazbayev, R., Varol, H. A., & Chan, M. Y. A Multitask Deep Learning Model for Food Scene Recognition and Portion Estimation—the Food Portion Benchmark (FPB) Dataset. *IEEE Access*, Vol. 13, 2025, pp. 152033-152045.
- [22] Evaluating a Multitask Artificial Intelligence Model Compared With Humans for Portion-Size Estimation. *The Journal of Nutrition*, 2026. <https://www.sciencedirect.com/science/article/abs/pii/S002231662600307X>
- [23] Schmidgall, S., Ziaei, R., Harris, C., Kim, J. W., Reis, E., Jopling, J., & Moor, M. AgentClinic: a multimodal agent benchmark to evaluate AI in simulated clinical environments. *npj Digital Medicine*, Vol. 9, Article 499, 2026. <https://link.springer.com/article/10.1038/s41746-026-02674-7>
- [24] Metwally, A., Gu, K., Zhan, J., Ayush, K., Yu, H., Paruchuri, A., Lee, A., He, Q., Zhang, Z., Galatzer-Levy, I., Prieto, X., Barakat, A., Graef, B., Yang, Y., McDuff, D., Winslow, B., Patel, S., Narayanswamy, G., Heneghan, C., Xu, M., Shreibati, J., Malhotra, M., Xu, O., Althoff, T., Faranesh, T., Hammerquist, N., & Srinivas, V. The Anatomy of a Personal Health Agent. *arXiv*, 2025. <https://research.google/pubs/the-anatomy-of-a-personal-health-agent/>
- [25] Wang, S., Sheng, G., Yan, H., Min, W., & Jiang, S. A comparative study of vision-language models for food ingredient recognition and nutrient estimation. *Current Research in Food Science*, Vol. 12, 101405, 2026. <https://doi.org/10.1016/j.crfs.2026.101405>
- [26] Min, W., et al. A survey on food computing. *ACM Computing Surveys (CSUR)*, 2019.